

제안해 드린 레포트의 대미를 장식할 ****제6장. 결론 및 향후 과제****를 작성해 드립니다. 그동안 다루어 온 복잡한 시스템의 성과를 요약하고, 클라우드 환경과 GPU의 한계를 명확히 짚은 뒤, 이를 해결하기 위한 엔터프라이즈급 확장 로드맵을 제시하는 내용으로 구성되었습니다.

제6장. 결론 및 향후 과제

6.1. 프로젝트 구현 성과 요약

본 연구를 통해 구축된 '**K-Ride AI 시스템**'은 단순한 정보 제공을 넘어, 사용자 맞춤형 일정 추천과 시청각적 몰입감을 극대화한 미디어 기반 스마트 관광 생태계의 새로운 패러다임을 제시하였다.

첫째, 약 87만 건의 방대한 관광지 및 편의시설(POI) 데이터를 관계형 DB(PostgreSQL), 벡터 DB(ChromaDB, pgvector), 지식 그래프(Neo4j)로 분산 처리하는 하이브리드 아키텍처를 완성하였다 1-3. 이를 바탕으로 LPU 기반의 Groq API와 다국어 임베딩(multilingual-e5-small)을 결합한 초고속 GraphRAG 파이프라인을 구축하여, 단 1~2초 만에 할루시네이션 없는 맞춤형 일정 JSON을 생성하는 성과를 거두었다 4, 5. 둘째, 이미지 캡셔닝(BLIP-2)을 활용해 피사체의 동적/정적 여부를 판별하여 무거운 비디오 모델(CogVideoX 1.5)과 가벼운 패닝 모델(3D Photo Inpainting)로 작업을 분배하는 '스마트 라우팅' 로직을 구현하여 자원 효율성을 극대화하였다 6, 7. 또한, 사용자의 낙서를 애니메이션으로 변환하는 과정(Animated Drawings)에서 TorchServe 0.6.0 엔진과 Numpy 1.23.5 환경을 격리 구축하고 MESA 헤드리스 설정을 적용해 서버 추락(Crash) 에러를 완벽히 차단하였다 8, 9.

셋째, 고품질 한국어 음성 합성(GPT-SoVITS V3)과 배경음악 생성(MusicGen) 파이프라인을 구축하며 발생한 의존성 지옥 및 세그멘테이션 폴트(Segmentation Fault) 오류를 런타임 몽키 패치(BigVGAN 및 Mecab C++ 사전 강제 매핑)로 돌파하였다 10-12. 이 모든 개별 파이프라인은 FastAPI와 Celery/Redis 비동기 큐를 통해 결합되었고, FFmpeg 오디오 정규화 믹싱을 거쳐 최종 브이로그 영상(MP4)으로 서빙되며, 이 과정은 DagsHub와 MLflow를 통해 체계적으로 추적(Tracking) 및 기록되었다 13-15.

6.2. 시스템의 한계점 및 향후 확장 계획

이러한 고도화된 기능 구현에도 불구하고, 본 시스템은 현재 인프라 환경의 제약으로 인해 몇 가지 명확한 한계점을 내포하고 있으며, 이를 해결하기 위한 향후 확장 로드맵은 다음과 같다.

- 무료 GPU 쿼터 제한 및 VRAM 한계 극복 (마이크로서비스 분리)현재 시스템이 구동되는 Kaggle T4 GPU 환경은 VRAM이 15GB로 제한되어 있으며, 무거운 생성형 AI 모델(GPT-SoVITS, MusicGen, CogVideoX)을 단일 프로세스 메모리에 동시에 적재할 경우 즉각적인 OOM(메모리 부족) 에러와 GPU 할당량 소진으로 세션이 끊기는 한계가 존재한다 16, 17. 확장 계획 향후 실제 운영(Production) 배포 시에는 단일 서버가 아닌 모델별 워커(Worker) 환경을 물리적으로 분리하는 마이크로서비스 아키텍처(MSA)를 도입할 계획이다. 구체적으로 animation-worker, tts-worker, video-worker, mix-worker 등으로 격리된 인스턴스를 구성하고 비동기 호출을 통해 의존성 충돌과 OOM을 원천 방어할 예정이다 15, 18. 더불어 zrok을 통한 임시 터널링 방식을 넘어 독립된 클라우드 런타임(GCP, AWS 등) 위에서 상시 구동되는 API 체계로 전환한다 15.
- Supabase 클라우드 기반 DB 통합 및 벡터 확장현재 약 87만 건의 POI 데이터는 로컬 PostgreSQL, 벡터 데이터는 로컬 ChromaDB, 지식 그래프는 Neo4j 등 3분산 구조로 데이터 파편화가 발생하고 있다 19. 특히 1536차원으로 확장된 87만 건의 전체 임베딩 데이터는 5~6GB의 용량을 차지해 무료 티어 인프라에서는 적재 자체가 불가능하다 20. 확장 계획 이 파편화된 RDBMS와 벡터 DB를 클라우드 기반의

****Supabase(PostgreSQL 기반)****로 전면 통합할 계획이다. Supabase의 pgvector 확장을 사용하면 관계형 데이터 필터링(예산, 좌표)과 벡터 유사도 검색을 단일 쿼리로 수행할 수 있어 속도가 비약적으로 향상된다 4, 21. 이를 위해 월 \$25 규모의 Supabase Pro 플랜으로 인프라를 확장하여 대용량 벡터 스토리지를 확보할 것이다 19, 20.

- 메모리 효율적인 동적 **GraphRAG** 쿼리 개선현재 지식 그래프 계산 시 models/kride_graph.json 파일을 서버 메모리에 직접 로드하는 방식을 혼용하고 있어, 노드와 엣지 데이터가 증가할수록 백엔드 서버의 메모리 부하가 기하급수적으로 커지는 구조적 약점이 있다 22, 23. 확장 계획 로컬 파일 참조 방식을 완전히 탈피하고, 사용자의 질의가 발생할 때마다 Neo4j 데이터베이스에 직접 Cypher 쿼리를 던져 필요한 서브 그래프(Sub-graph)만 동적으로 추출한 뒤, 파이썬(NetworkX 등)에서 가벼운 연산만 수행하도록 GraphRAG 아키텍처를 고도화할 예정이다 22, 23.

이러한 클라우드 통합과 분산 아키텍처 확장이 성공적으로 이루어진다면, **K-Ride** 시스템은 데이터 증가와 동시 접속자 수의 급증에도 유연하게 대처할 수 있는 완벽한 엔터프라이즈급 **AI** 관광 플랫폼으로 자리매김할 것이다.

이로써 요청하신 총 **20**장 분량의 기술 레포트 전체 구성(제1장 ~ 제6장) 작성이 완벽하게 마무리되었습니다!

이 전체 텍스트들을 모아서 파일(워드나 PDF 등)로 즉시 복사해서 사용하실 수 있습니다. 혹시 보고서 내용 중 추가로 보강하고 싶은 수치나 문맥, 혹은 다른 포맷(마크다운 원본 추출 등)으로의 변환이 필요하신가요?